Documentação de algoritmos para Vigilância Sindrômica do pacote RNSSP

Responsável técnica: Elisângela Ap. da Silva Lizzi

Contents

0.1 Introdução . . . 3
0.1.1 Obtenção dos dados . . . 3
0.2 Implementação no contexto brasileiro . . . 3

1 Algoritmos de detecção em Vigilância Sindrômica 5
1.1 Média Móvel Exponencialmente Ponderada (EWMA) . . . 5
1.1.1 Conceito Estatístico . . . 5
1.1.2 Quando utilizar . . . 5
1.1.3 Vantagens . . . 5
1.1.4 Limitações . . . 6
1.1.5 Implementação no R com `RNSSP` . . . 6
1.1.6 Argumento Parâmetros . . . 6
1.2 Regressão Múltipla Adaptativa . . . 7
1.2.1 Conceito Estatístico . . . 7
1.2.2 Aplicação em Vigilância Sindrômica . . . 7
1.2.3 Quando utilizar . . . 7
1.2.4 Vantagens . . . 7
1.2.5 Limitações . . . 8
1.2.6 Implementação no R com RNSSP . . . 8
1.2.7 Argumentos e Parâmetros . . . 8
1.3 Modelo Híbrido Regressão/EWMA . . . 9
1.3.1 Conceito Estatístico . . . 9
1.3.2 Aplicação em Vigilância Sindrômica . . . 10
1.3.3 Quando utilizar . . . 10
1.3.4 Vantagens . . . 10
1.3.5 Limitações . . . 10
1.3.6 Implementação no R com `RNSSP` . . . 10

1.3.7 Argumentos e Parâmetros . . . 10
1.4 O Método de Serfling . . . 12
1.4.1 Conceito e Regressão Harmônica . . . 12
1.4.2 Definição matemática e decomposição . . . 12
1.4.3 Dinâmica de ajuste e identificação de epidemias . . . 13
1.4.4 Quando Utilizar . . . 13
1.4.5 Vantagens . . . 13
1.4.6 Limitações . . . 13
1.4.7 Implementação no R com `RNSSP` . . . 14
1.4.8 Argumentos e Parâmetros . . . 14
1.5 Detector Temporal de Farrington . . . 16
1.5.1 Conceito . . . 16
1.5.2 Aplicação em Vigilância Sindrômica . . . 17
1.5.3 Quando Utilizar . . . 18
1.5.4 Vantagens . . . 18
1.5.5 Implementação no R com `RNSSP` . . . 18
1.5.6 Argumentos e Parâmetros . . . 18
1.6 Modelo Binomial Negativo . . . 19
1.6.1 Conceito Estatístico . . . 19
1.6.2 Aplicação em Vigilância Sindrômica . . . 20
1.6.3 Quando utilizar . . . 21
1.6.4 Vantagens . . . 21
1.6.5 Limitações . . . 21
1.6.6 Implementação no R com `RNSSP` . . . 21
1.6.7 Argumentos e Parâmetros . . . 21
1.7 . . . 24

2 Comparação dos métodos **25**
2.0.1 Nota Técnica . . . 25
2.0.2 Critérios práticos e técnicos da escolha do algoritmo . . . 26

3 Referencias Bibliográficas **27**

0.1 Introdução

A vigilância sindrômica tem como principal objetivo identificar precocemente alterações incomuns no padrão de ocorrência de eventos de saúde. Para isso, são empregados algoritmos estatísticos capazes de monitorar séries temporais de contagens e detectar desvios em relação ao comportamento esperado (E(Xt))

De forma geral, esses métodos estimam uma linha de base (*baseline*) a partir do histórico dos dados e avaliam se os valores observados ultrapassam limites estatísticos previamente estabelecidos, indicando a possibilidade de surtos, epidemias ou eventos de interesse em saúde pública.

No ambiente computacional **R**, o pacote **RNSSP** (*R National Syndromic Surveillance Program*) disponibiliza ferramentas para implementação desses algoritmos, amplamente utilizados em sistemas de vigilância sindrômica vinculados ao CDC (*Centers for Disease Control and Prevention*).Dentro do contexto do sistema de saúde do Brasil (com apoio da OPAS - Organização Pan-Americana da Saúde e secretarias estaduais e municipais de saúde), os algoritmos deste pacote em linguagem R estão sendo estudados e aplicados para a construção de uma Vigilância Sindrômica baseada em dados assistenciais

O objetivo da Vigilância Sindrômica nas UPAs No Brasil, as Unidades de Pronto Atendimento (UPAs) são a principal porta de entrada para casos agudos. A vigilância sindrômica utiliza os dados desses atendimentos para detectar e monitorar doenças rastreando os sintomas dos pacientes antes mesmo da confirmação de um diagnóstico laboratorial (como o teste de Dengue ou COVID-19). Isso funciona como um sistema de alerta precoce (quase em tempo real) para que as autoridades identifiquem surtos de forma rápida

0.1.1 Obtenção dos dados

Os dados chegam até o algoritmo usando ferramentas de mineração de texto, o projeto realiza primeiro uma etapa de mineração de texto utilizando a linguagem R O processo envolve etapas sequenciais, sendo:

1)Extrair os textos que os médicos ou enfermeiros digitam livremente no prontuário eletrônico (campos de "Sintomas/Queixas" ou "Anamnese")

2)Fazer uma limpeza e tratamento da linguagem natural (removendo palavras sem valor analítico, tratando negações como "nega febre")

3)Agrupar os sintomas detectados para formar as "síndromes" que serão alimentadas no algoritmo. Por exemplo, criar uma síndrome de arbovirose combinando as palavras-chave: febre + (cefaleia OU mialgia OU dor retro orbitária)

Ao final tem-se um banco de dados estruturado com as contagens de casos.

0.2 Implementação no contexto brasileiro

Este processo integrado, que une a inteligência em mineração de texto (*text mining*) de prontuários eletrônicos brasileiros aos modelos estatísticos avançados do pacote `Rnssp`, já se encontra em fase de provas de conceito e validações estratégicas em diversos estados e municípios (como Rio de Janeiro, Santa Catarina, Minas Gerais, Bahia, Amazonas, entre outros). Os *outputs* e alertas gerados por esses algoritmos são consolidados e exibidos em painéis visuais (*dashboards*) interativos, desenhados especificamente para guiar e acelerar a tomada de decisão das equipes de resposta rápida do Sistema Único de Saúde (SUS).

Diante desse cenário de expansão tecnológica, este relatório foi estruturado para explorar a fundo as capacidades de análise de dados em saúde, destrinchando as ferramentas estatísticas disponíveis no ecossistema `Rnssp`. O documento descreve de forma organizada a arquitetura de argumentos, as parametrizações ideais e o funcionamento interno de cada um dos 6 algoritmos de detecção de anomalias analíticas voltados à Vigilância Sindrômica.

O propósito fundamental e eixo central deste material é servir como um manual técnico de referência e padronização para as secretarias municipais e estaduais de saúde que estão incorporando a análise sindrômica

em suas rotinas de monitoramento. Ao consolidar conceitos complexos, códigos comentados e critérios de aplicabilidade em um guia único e centralizado, este documento constitui uma ferramenta indispensável a ser entregue aos responsáveis técnicos e gestores, assegurando a governança de dados, a reprodutibilidade das análises e a sustentabilidade das operações de vigilância epidemiológica no território nacional.

1 Algoritmos de detecção em Vigilância Sindrômica

Em vigilância sindrômica, trabalhamos essencialmente com uma série temporal de contagens Y_t, em que t representa a unidade de tempo (dias, semanas epidemiológicas). Essas contagens englobam atendimentos em prontos-socorros, notificações sindrômicas, admissões hospitalares por síndromes respiratórias, gastrointestinais, entre outras.

O objetivo do algoritmo é responder, sob uma ótica probabilística: *"O número observado hoje/esta semana é estatisticamente esperado ou representa um excesso significativo capaz de indicar um surto?"*

Os algoritmos estimam a dinâmica basal da série eliminando ruídos e avaliam o comportamento atual contra um limiar crítico. Ao fazer isso, os sistemas de vigilância sindrômica operam na vanguarda da epidemiologia, permitindo detectar aumentos inesperados de casos antes mesmo da confirmação laboratorial dos patógenos circulantes. Na sequencia veremos os métodos disponíveis e suas respectivas características, indicações de uso, vantagens lim itações e funções no `Rnssp` para organização.

1.1 Média Móvel Exponencialmente Ponderada (EWMA)

1.1.1 Conceito Estatístico

O método **Exponentially Weighted Moving Average (EWMA)** realiza a suavização da série temporal atribuindo pesos que decrescem geometricamente à medida que as observações se tornam mais distantes no tempo. Diferente de uma média móvel simples, ele preserva a memória do processo, mas prioriza o comportamento imediato.

A estatística de teste EWMA é definida recursivamente por:

$$Z_t = \lambda Y_t + (1 - \lambda) Z_{t-1}$$

Onde: - Y_t: valor observado no instante t. - Z_t: valor suavizado pelo EWMA (estatística de controle). - λ: parâmetro de suavização ($0 < \lambda \leq 1$), que dita a velocidade de amortecimento dos pesos. Valores baixos de λ dão maior peso ao histórico retrospectivo; valores altos tornam o algoritmo altamente sensível a flutuações imediatas. - O valor inicial Z_0 é comumente definido como a média histórica do processo (μ_0).

Os limites de controle para a detecção de anomalias dependem da variância teórica da estatística Z_t, dada por:

$$\sigma^2_{Z_t} = \sigma^2 \left(\frac{\lambda}{2 - \lambda} \right) [1 - (1 - \lambda)^{2t}]$$

O alarme é disparado se Y_t ou Z_t ultrapassar o limite superior: $LSC = \mu_0 + k\sigma_{Z_t}$, onde k determina o rigor do teste (nível de significância para o Erro Tipo I).

1.1.2 Quando utilizar

- Séries temporais de curta duração ou monitoramento diário operacional.
- Cenários com indisponibilidade de longos históricos de dados para modelagem complexa.
- Detecção de pequenas alterações graduais e persistentes no nível médio da série (*shifts*).

1.1.3 Vantagens

- Simplicidade matemática e baixo custo computacional.
- Excelente sensibilidade para capturar inflexões recentes na curva de dados.
- Requer pequeno volume de dados históricos para inicialização.

1.1.4 Limitações

- Não modela componentes estruturais como sazonalidade anual e tendências complexas de forma explícita.
- Pode inflacionar a taxa de falsos positivos em séries que apresentam forte variabilidade estocástica intrínseca ou sob distribuições com caudas pesadas.

1.1.5 Implementação no R com `RNSSP`

No pacote `RNSSP`, o controle adaptado do algoritmo EWMA (focado no padrão do CDC/NSSP) é aplicado por meio da função Média Móvel Exponencialmente Ponderada (`alert_ewma`).

Função: `alert_ewma(df, t = date, y = count, B = 28, g = 2, w1 = 0.4, w2 = 0.9)`

1.1.6 Argumento Parâmetros

- `df`: O conjunto de dados bruto (pode ser um `data.frame`, `tibble` ou `lazy data frame`).
- `t`: Nome da coluna que contém os registros temporais (obrigatório formato `Date`). O padrão assume a coluna `date`.
- `y`: Nome da coluna numérica que contém as contagens ou percentuais a serem testados. O padrão assume a coluna `count`.
- `B` **(Baseline/Linha de Base):** Quantidade de dias passados que serão utilizados para estimar a média móvel, os desvios padrão e calificar o peso exponencial. O padrão adotado é **28 dias** (alinhado com o sistema ESSENCE do CDC).
- `g` **(Guardband/Margem de Segurança):** O intervalo de dias que separa o dia que está sendo testado (hoje) do fim do período de referência. Serve para evitar que o surto em andamento inflacione a linha de base. O padrão é **2 dias**.
- `w1` **(Suavização Gradual):** Coeficiente de peso para eventos de evolução lenta/gradual. Deve estar entre 0 e 1 (recomendado: 0,3 a 0,5). O padrão é **0,4**.
- `w2` **(Suavização Súbita):** Coeficiente de peso para eventos com explosão rápida/súbita de casos. Deve estar entre 0 e 1 (recomendado: >0,7). O padrão é **0,9** (aproxima-se do clássico algoritmo C2).

```r
library(Rnssp)
library(ggplot2)
## Alisamento EWMA
# Exemplo1
df <- data.frame(
  date = seq.Date(as.Date("2020-01-01"), as.Date("2020-12-31"), by = 1),
  count = floor(runif(366, min = 0, max = 101))
)

head(df)
```

```
##         date count
## 1 2020-01-01    62
## 2 2020-01-02    59
## 3 2020-01-03    52
## 4 2020-01-04    74
## 5 2020-01-05    17
## 6 2020-01-06    79
```

```r
df_ewma <- alert_ewma(df)

head(df_ewma)
```

```
## # A tibble: 6 x 6
##   date       count baseline_expected test_statistic p.value alert
##   <date>     <dbl>             <dbl>          <dbl>   <dbl> <chr>
## 1 2020-01-01    62                NA             NA      NA grey
## 2 2020-01-02    59                NA             NA      NA grey
## 3 2020-01-03    52                NA             NA      NA grey
## 4 2020-01-04    74                NA             NA      NA grey
## 5 2020-01-05    17                NA             NA      NA grey
## 6 2020-01-06    79                NA             NA      NA grey
```

1.2 Regressão Múltipla Adaptativa

1.2.1 Conceito Estatístico

A Regressão Múltipla Adaptativa modela a série de contagens estimando explicitamente a estrutura determinística do processo por meio de uma função de regressão linear ou linearizada. A modelagem decompõe a série em um intercepto, uma tendência temporal (geralmente linear ou polinomial) e variações cíclicas sazonais calculadas via funções trigonométricas.

O modelo base estruturado assume a forma harmônica:

$$Y_t = \beta_0 + \beta_1 t + \beta_2 \sin\left(\frac{2\pi t}{s}\right) + \beta_3 \cos\left(\frac{2\pi t}{s}\right) + \varepsilon_t$$

Onde:t: índice temporal contínuo. s: comprimento do ciclo sazonal ($s = 7$ para ciclos semanais dentro do mês; $s = 365.25$ para ciclos diários anuais, etc.). β_2, β_3: coeficientes que determinam conjuntamente a amplitude e a fase (o tempo exato do pico) da flutuação sazonal. ε_t: erro aleatório residual, modelado sob hipótese de homocedasticidade $\sim N(0, \sigma^2)$ ou estendido para distribuições generalizadas.

O termo Adaptativa se refere à reestimação contínua dos coeficientes em janelas móveis de tempo, permitindo que os coeficientes acompanhem modificações graduais na dinâmica populacional e epidemiológica.

1.2.2 Aplicação em Vigilância Sindrômica

Utilizada como o motor de estimação do comportamento esperado para endemias sazonais típicas, como vírus respiratórios (Influenza, VSR) e arboviroses (Dengue, Chikungunya).

1.2.3 Quando utilizar

Séries históricas longas (mínimo de 2 a 3 anos para correta parametrização cíclica). Presença marcante de sazonalidade e tendências de longo prazo. Quando há necessidade de controlar efeitos de calendário (ex: dias da semana, feriados) como covariáveis.

1.2.4 Vantagens

Modela a sazonalidade explicitamente, o que mitiga a distorção introduzida por flutuações climáticas ou sazonais esperadas. Redução de falsos positivos: O excesso de falsos positivos introduz ruído na modelagem

de séries temporais na vigilância em saúde. Isso pode distorcer a curva epidêmica e gerar alarmes falsos de surtos (falsos sinais em modelos de detecção).

A regressão adaptativa trata esse problema ao ajustar a linha de base para o que é sazonalmente esperado, evitando alarmes causados meramente pela chegada do inverno ou do verão.Permite a inserção de covariáveis socioambientais e clínicas para inferência epidemiológica.

1.2.5 Limitações

Requer maior volume de dados históricos limpos para evitar o sobreajuste (overfitting).Pode apresentar perda drástica de desempenho preditivo ou atraso de adaptação diante de quebras estruturais abruptas (como a introdução de uma nova variante ou um lockdown).

1.2.6 Implementação no R com RNSSP

No pacote RNSSP, a regressão adaptativa automatizada baseia-se nos critérios clássicos do algoritmo de regressão linear adaptativa do NSSP (frequentemente associado às variações dos algoritmos de regressão locais e detecção de anomalias). É executada pela função `alert_regression`.

Função: `alert_regression(df, t = date, y = count, B = 28, g = 2)`

1.2.7 Argumentos e Parâmetros

- **`df`**, **`t`**, **`y`**: Formato padrão de entrada de dados do pacote.
- **`B` (Tamanho da Linha de Base):** Número bruto de dias que serão inseridos na janela móvel diária para ajustar a regressão linear por mínimos quadrados ordinários (OLS). O padrão é **28 dias**.
- **`g` (Margem de Segurança):** Faixa de segurança em dias para separar as observações de treino da data atual de teste. O padrão é **2 dias**.
- **Funcionamento interno:** Ao contrário do EWMA, este método adiciona termos internos adicionais no modelo para tratar de forma robusta as **tendências lineares e os efeitos do dia da semana (dummies semanais)**.

```r
# Regressão múltipla adaptativa

# Example 1
df <- data.frame(
  date = seq.Date(as.Date("2020-01-01"), as.Date("2020-12-31"), by = 1),
  count = floor(runif(366, min = 0, max = 101))
)

head(df)
```

```
##         date count
## 1 2020-01-01    82
## 2 2020-01-02    72
## 3 2020-01-03    78
## 4 2020-01-04    86
## 5 2020-01-05    53
## 6 2020-01-06    55
```

```r
df_regression <- alert_regression(df)
head(df_regression)
```

```
## # A tibble: 6 x 8
##   date       count baseline_expected test_statistic p.value sigma
##   <date>     <dbl>             <dbl>          <dbl>   <dbl> <dbl>
## 1 2020-01-01    82                NA             NA      NA    NA
## 2 2020-01-02    72                NA             NA      NA    NA
## 3 2020-01-03    78                NA             NA      NA    NA
## 4 2020-01-04    86                NA             NA      NA    NA
## 5 2020-01-05    53                NA             NA      NA    NA
## 6 2020-01-06    55                NA             NA      NA    NA
## # i 2 more variables: adjusted_r_squared <dbl>, alert <chr>
```

```
df <- data.frame(
  Date = seq.Date(as.Date("2020-01-01"), as.Date("2020-12-31"), by = 1),
  percent = runif(366)
)

head(df)
```

```
##         Date   percent
## 1 2020-01-01 0.7676073
## 2 2020-01-02 0.6899907
## 3 2020-01-03 0.5571595
## 4 2020-01-04 0.9578576
## 5 2020-01-05 0.4014839
## 6 2020-01-06 0.1744419
```

```
df_regression <- alert_regression(df, t = Date, y = percent)
head(df_regression)
```

```
## # A tibble: 6 x 8
##   Date       percent baseline_expected test_statistic p.value sigma
##   <date>       <dbl>             <dbl>          <dbl>   <dbl> <dbl>
## 1 2020-01-01   0.768                NA             NA      NA    NA
## 2 2020-01-02   0.690                NA             NA      NA    NA
## 3 2020-01-03   0.557                NA             NA      NA    NA
## 4 2020-01-04   0.958                NA             NA      NA    NA
## 5 2020-01-05   0.401                NA             NA      NA    NA
## 6 2020-01-06   0.174                NA             NA      NA    NA
## # i 2 more variables: adjusted_r_squared <dbl>, alert <chr>
```

1.3 Modelo Híbrido Regressão/EWMA

1.3.1 Conceito Estatístico

O modelo híbrido unifica a capacidade de filtragem estrutural da regressão linear com a sensibilidade de detecção de pequenas variações do algoritmo EWMA. O processo é executado em dois estágios sequenciais:

Estágio 1 (Filtragem): Ajusta-se um modelo de regressão múltipla para capturar os componentes macro da série temporal (tendência e sazonalidade), gerando os valores preditos $\hat{Y}_t$. A partir disso, extrai-se a série de resíduos purificados (erros de previsão):

$$e_t = Y_t - \hat{Y}_t$$

Estágio 2 (Detecção): A série de resíduos e_t, que idealmente deve se comportar como um ruído branco na ausência de anomalias, é submetida ao algoritmo EWMA. A estatística de controle passa a rastrear os desvios residuais:

$$Z_t = \lambda e_t + (1 - \lambda) Z_{t-1}$$

Desvios persistentes dos resíduos acima de zero indicam que a contagem observada está sistematicamente maior do que o modelo estrutural previu, disparando o alerta de anomalia.

1.3.2 Aplicação em Vigilância Sindrômica

Ideal para sistemas de monitoramento automatizados em tempo real de nível hospitalar ou municipal, operando como um sensor sensível e ao mesmo tempo blindado contra flutuações sazonais normais.

1.3.3 Quando utilizar

- Séries complexas que possuem forte tendência e sazonalidade concomitantes.
- Sistemas de monitoramento contínuo onde deseja-se detectar desvios de pequena magnitude antes que escalem para surtos francos.

1.3.4 Vantagens

- **Arquitetura robusta:** ao remover a estrutura determinística na primeira etapa, a estatística EWMA trabalha livre de tendências, o que reduz substancialmente a taxa de alarmes falsos em comparação ao EWMA puro.
- Alta sensibilidade para desvios pequenos e cumulativos.

1.3.5 Limitações

- Maior complexidade de calibração matemática e processamento computacional.
- Exige histórico consistente e sem falhas para que a etapa de regressão não gere resíduos severamente enviesados.

1.3.6 Implementação no R com `RNSSP`

No `RNSSP`, a combinação analítica híbrida que segue o padrão adaptado de regressão acoplada ao monitoramento de resíduos pode ser executada por pipelines combinadas ou através das parametrizações avançadas de controle de alertas do pacote, mimetizando os sistemas automáticos do BioSense Platform. Neste caso, temos a função do modelos de Alternância/Switch Regressão-EWMA (`alert_switch`), sendo:

Função: `alert_switch(df, t = date, y = count, B = 28, g = 2, w1 = 0.4, w2 = 0.9)`

1.3.7 Argumentos e Parâmetros

- **`df`**, **`t`**, **`y`**: Formato padrão de entrada de dados do pacote.
- **`B`** e **`g`**: Parâmetros de tamanho de baseline (28 dias) e faixa de guarda (2 dias) passados para os blocos de teste.
- **`w1`** e **`w2`**: Coeficientes de peso do EWMA (0,4 e 0,9, respectivamente) utilizados caso o modelo realize a transição automática.

- **Lógica do Switch:** O algoritmo tenta rodar primeiro o modelo de `alert_regression`. Ele extrai o R^2 ajustado.
  - Se $R^2 \geq 0.60$: O modelo de regressão descreve bem o comportamento e seu alerta é gerado.
  - Se $R^2 < 0.60$: A série temporal é classificada como esparsa ou ruidosa e o algoritmo altera em tempo de execução para a lógica estável do `alert_ewma`.

```
# Exemplo1
df <- data.frame(
  date = seq.Date(as.Date("2020-01-01"), as.Date("2020-12-31"), by = 1),
  count = floor(runif(366, min = 0, max = 101))
)

head(df)
```

```
##         date count
## 1 2020-01-01    99
## 2 2020-01-02    75
## 3 2020-01-03    28
## 4 2020-01-04    59
## 5 2020-01-05    73
## 6 2020-01-06    69
```

```
df_switch <- alert_switch(df)

head(df_switch)
```

```
## # A tibble: 6 x 7
##   date       count baseline_expected test_statistic p.value alert detector
##   <date>     <dbl>             <dbl>          <dbl>   <dbl> <chr> <chr>
## 1 2020-01-01    99                NA             NA      NA grey  <NA>
## 2 2020-01-02    75                NA             NA      NA grey  <NA>
## 3 2020-01-03    28                NA             NA      NA grey  <NA>
## 4 2020-01-04    59                NA             NA      NA grey  <NA>
## 5 2020-01-05    73                NA             NA      NA grey  <NA>
## 6 2020-01-06    69                NA             NA      NA grey  <NA>
```

```
# Exemplo 2
df <- data.frame(
  Date = seq.Date(as.Date("2020-01-01"), as.Date("2020-12-31"), by = 1),
  percent = runif(366)
)

head(df)
```

```
##         Date   percent
## 1 2020-01-01 0.6390265
## 2 2020-01-02 0.7474570
## 3 2020-01-03 0.7081439
## 4 2020-01-04 0.3660701
## 5 2020-01-05 0.3027903
## 6 2020-01-06 0.2037682
```

```r
df_switch <- alert_switch(df, t = Date, y = percent)
head(df_switch)
```

```
## # A tibble: 6 x 7
##   Date       percent baseline_expected test_statistic p.value alert detector
##   <date>       <dbl>             <dbl>          <dbl>   <dbl> <chr> <chr>
## 1 2020-01-01   0.639                NA             NA      NA grey  <NA>
## 2 2020-01-02   0.747                NA             NA      NA grey  <NA>
## 3 2020-01-03   0.708                NA             NA      NA grey  <NA>
## 4 2020-01-04   0.366                NA             NA      NA grey  <NA>
## 5 2020-01-05   0.303                NA             NA      NA grey  <NA>
## 6 2020-01-06   0.204                NA             NA      NA grey  <NA>
```

1.4 O Método de Serfling

1.4.1 Conceito e Regressão Harmônica

O **Método de Serfling** representa o marco histórico da modelagem harmônica aplicada à vigilância da mortalidade e morbidade por Influenza e Pneumonia. Fundamenta-se no uso da **Regressão Harmônica**, uma técnica que substitui o uso ineficiente de múltiplas variáveis categóricas para meses ou semanas por uma combinação linear de funções trigonométricas contínuas.

Geometricamente, a inclusão combinada de senos e cossenos de mesma frequência em um modelo linear permite capturar as duas propriedades fundamentais de qualquer ciclo biológico: * **A amplitude:** Mede a magnitude do impacto estacional (o tamanho da onda, do ponto médio ao pico). * **A fase:** Mede o deslocamento temporal do ciclo (identificando matematicamente em qual semana ou mês exato ocorre o pico epidemiológico).

Ao parametrizar a oscilação como uma função contínua do tempo, o modelo evita a perda de graus de liberdade e suaviza a transição entre os períodos sazonais, reproduzindo com fidelidade a dinâmica de transmissão biológica, que não respeita barreiras artificiais de viradas de meses no calendário.

1.4.2 Definição matemática e decomposição

A formulação matemática clássica de Serfling modela a dinâmica de base sob a seguinte equação estrutural:

$$Y_t = \beta_0 + \beta_1 t + \beta_2 \sin\left(\frac{2\pi t}{s}\right) + \beta_3 \cos\left(\frac{2\pi t}{s}\right) + \epsilon_t$$

Onde: * Y_t: Taxa de incidência, óbitos por causas respiratórias ou Infarto Agudo do Miocárdio (IAM) no tempo t. * β_0: Intercepto do modelo, indicando o nível médio basal inicial da série. * $\beta_1 t$: Termo de **tendência linear de longo prazo**. Absorve variações seculares decorrentes do crescimento ou envelhecimento demográfico e transições tecnológicas nos sistemas de registro de saúde. * $\sin\left(\frac{2\pi t}{s}\right)$ **e** $\cos\left(\frac{2\pi t}{s}\right)$: Termos **harmônicos fundamentais** de periodicidade s (ex: $s = 52$ para dados semanais ou $s = 365.25$ para dados diários). O argumento em radianos garante o fechamento perfeito do ciclo a cada período s. * ϵ_t: Erro aleatório assumido como independentemente e identicamente distribuído sob pressuposto gaussiano $\sim N(0, \sigma^2)$.

1.4.2.1 Complemento Analítico: Cálculo da Amplitude e Fase

Epidemiologicamente, extraímos a **Amplitude (A)** real do ciclo sazonal e a **Fase (ψ)** (ponto de pico) a partir dos coeficientes estimados β_2 e β_3 utilizando as identidades trigonométricas:

$$A = \sqrt{\beta_2^2 + \beta_3^2}$$

$$\psi = \arctan\left(\frac{\beta_3}{\beta_2}\right)$$

1.4.3 Dinâmica de ajuste e identificação de epidemias

O método operacionaliza-se estritamente através de quatro fases sequenciais:

1. **Exclusão de Períodos Epidêmicos (Fase de Treinamento):** Removem-se de forma iterativa ou clínica os dados históricos nos quais ocorreram epidemias confirmadas. O objetivo é isolar o comportamento puramente endêmico.
2. **Ajuste da Linha de Base:** Estima-se os parâmetros β via Mínimos Quadrados Ordinários (MQO) utilizando apenas a série truncada não epidêmica. A curva resultante projeta o comportamento teórico esperado da doença caso nenhuma epidemia ocorresse.
3. **Construção do Limiar Epidêmico:** Calcula-se a variância residual do modelo ($\hat{\sigma}^2$). O limite superior de controle (limiar de alerta) é tradicionalmente fixado no intervalo de confiança de uma cauda, estabelecido como:

$$LSC_t = \hat{Y}_t + 1,96\hat{\sigma} \quad \text{(ou baseado no percentil 95\%)}$$

4. **Cálculo do Excesso (Detecção de Anomalias):** Ao confrontar a série real com o modelo projetado fora da amostra (*out-of-sample*), define-se o excesso de mortalidade/morbidade como $E_t = Y_t - \hat{Y}_t$, disparando alertas formais sempre que $Y_t > LSC_t$ de forma sustentada.

1.4.4 Quando Utilizar

- Monitoramento de síndromes respiratórias agudas graves (SRAG), gripe e Influenza.
- Avaliação de excesso de mortalidade por causas cardiovasculares (ex: IAM) associadas a estressores sazonais climáticos ou infecciosos.
- Séries longas estáveis com comportamento estacional anual bem marcado.

1.4.5 Vantagens

- Elevada interpretabilidade epidemiológica direta dos parâmetros estimáveis.
- Representação matemática elegante e contínua de ciclos sazonais complexos.
- Padrão de referência histórico para cálculo de impacto de pandemias (como o excesso de óbitos).

1.4.6 Limitações

- Assume estabilidade estrita na amplitude e fase da sazonalidade ao longo dos anos.
- Sensível a problemas de autocorrelação nos resíduos, o que pode distorcer a estimativa de $\hat{\sigma}$ e inflacionar falsos positivos se não corrigida por modelagem autorregressiva complementar (ex: termos ARMA).

1.4.7 Implementação no R com `RNSSP`

Modelagem manual do algoritmo de Serfling para o monitoramento de dados epidemiológicos semanais, usando a documentação do Método Serfling Original (`alert_serfling`)

Função: `alert_serfling(df, t = date, y = count, baseline_end)`

1.4.8 Argumentos e Parâmetros

- **`df`**, **`t`**, **`y`**: Formato padrão de entrada de dados do pacote.
- **`baseline_end`**: Argumento **obrigatório** (formato `Date`). Especifica a data em que finaliza o período estável histórico (mínimo recomendado de 5 anos) para criar os parâmetros de previsão harmônica.
- **Funcionamento interno:** O algoritmo automaticamente identifica e **remove da linha de base de treino as semanas consideradas como "período epidêmico clássico"** (meses de outubro a maio, padronizados para Influenza sazonal) antes de rodar os termos de Fourier (senos e cossenos de primeira ordem), limpando a curva basal para calcular o excesso de eventos.

```r
#Método Serfling original para séries temporais semanais

# Example 1
df <- data.frame(
  date = seq(as.Date("2014-01-05"), as.Date("2022-02-05"), "weeks"),
  count = rpois(length(seq(as.Date("2014-01-05"), as.Date("2022-02-05"), "weeks")), 25)
)

head(df)
```

```
##         date count
## 1 2014-01-05    21
## 2 2014-01-12    28
## 3 2014-01-19    18
## 4 2014-01-26    16
## 5 2014-02-02    29
## 6 2014-02-09    18
```

```r
df_serfling <- alert_serfling(df, baseline_end = as.Date("2020-03-01"))

head(df_serfling)
```

```
## # A tibble: 6 x 9
##   date       count t              y estimate threshold split     epidemic_period
##   <date>     <dbl> <date>     <dbl>    <dbl>     <dbl> <fct>     <lgl>
## 1 2014-01-05    21 2014-01-05    21     26.7      39.6 Baseline~ TRUE
## 2 2014-01-12    28 2014-01-12    28     26.7      39.7 Baseline~ TRUE
## 3 2014-01-19    18 2014-01-19    18     26.7      39.8 Baseline~ TRUE
## 4 2014-01-26    16 2014-01-26    16     26.6      39.8 Baseline~ TRUE
## 5 2014-02-02    29 2014-02-02    29     26.6      39.8 Baseline~ TRUE
## 6 2014-02-09    18 2014-02-09    18     26.5      39.7 Baseline~ TRUE
## # i 1 more variable: alarm <lgl>
```

```r
# Example 2
library(ggplot2)

simulated_ts <- simulated_data

## Time series with seasonality, moderate counts
ts1 <- subset(simulated_ts, id == "Scenario #1")

head(ts1)
```

```
## # A tibble: 6 x 5
##   date        week  year cases id
##   <date>     <dbl> <dbl> <dbl> <chr>
## 1 2017-01-01     1  2017    15 Scenario #1
## 2 2017-01-08     2  2017    12 Scenario #1
## 3 2017-01-15     3  2017    13 Scenario #1
## 4 2017-01-22     4  2017    11 Scenario #1
## 5 2017-01-29     5  2017    14 Scenario #1
## 6 2017-02-05     6  2017    16 Scenario #1
```

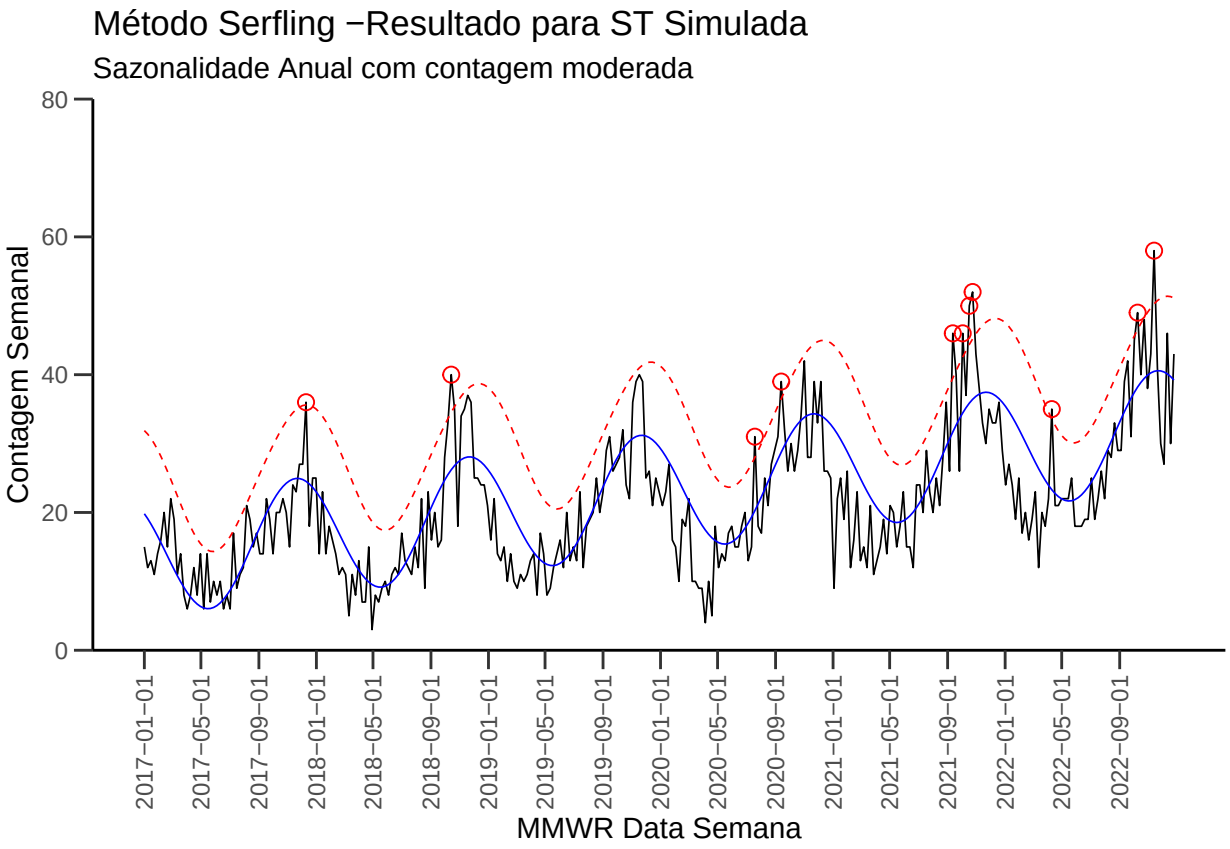
```r
df_serfling <- alert_serfling(ts1, t = date, y = cases,
                              baseline_end = as.Date("2021-12-26"))

head(df_serfling)
```

```
## # A tibble: 6 x 12
##   date        week  year cases id      t              y estimate threshold split
##   <date>     <dbl> <dbl> <dbl> <chr>   <date>     <dbl>    <dbl>     <dbl> <fct>
## 1 2017-01-01     1  2017    15 Scenar~ 2017-01-01    15     19.8      31.9 Base~
## 2 2017-01-08     2  2017    12 Scenar~ 2017-01-08    12     19.1      31.4 Base~
## 3 2017-01-15     3  2017    13 Scenar~ 2017-01-15    13     18.3      30.7 Base~
## 4 2017-01-22     4  2017    11 Scenar~ 2017-01-22    11     17.5      30.0 Base~
## 5 2017-01-29     5  2017    14 Scenar~ 2017-01-29    14     16.6      29.1 Base~
## 6 2017-02-05     6  2017    16 Scenar~ 2017-02-05    16     15.6      28.2 Base~
## # i 2 more variables: epidemic_period <lgl>, alarm <lgl>
```

```r
### Visualize alert
df_serfling %>%
  ggplot() +
  theme_classic() +
  geom_line(aes(x = date, y = cases), linewidth = 0.3) +
  geom_line(aes(x = date, y = estimate), color = "blue", linewidth = 0.3) +
  geom_line(aes(x = date, y = threshold), color = "red", linewidth = 0.3,
            linetype = "dashed") +
  geom_point(data = subset(df_serfling, alarm), aes(x = date, y = cases),
             color = "red", shape = 21, size = 2.5) +
  scale_y_continuous(
    limits = c(0, 80),
    expand = c(0, 0),
    name = "Contagem Semanal"
  ) +
  scale_x_date(
```

```
    breaks = seq.Date(from = min(ts1$date), to = max(ts1$date), by = "4 month"),
    name = "MMWR Data Semana"
  ) +
  theme(
    axis.text.x = element_text(angle = 90, vjust = 0.5),
    axis.ticks.length = unit(0.25, "cm")
  ) +
  labs(
    title = "Método Serfling -Resultado para ST Simulada ",
    subtitle = "Sazonalidade Anual com contagem moderada"
  )
```



1.5 Detector Temporal de Farrington

1.5.1 Conceito

O algoritmo de Farrington é um método estatístico desenvolvido especificamente para a detecção de anomalias e surtos em séries temporais de dados de contagem (valores inteiros). O modelo assume uma distribuição baseada em **Modelos Lineares Generalizados (GLM)** para prever o número esperado de casos em uma determinada unidade de tempo (geralmente semanas).

Existem duas formulações principais para o cálculo e previsão dos casos e limiares:

1.5.1.1 1. Abordagem original (Algoritmo clássico)

Utiliza uma regressão sob a distribuição de probabilidade **Quase-Poisson** para modelar o valor esperado $E(Y_t) = \mu_t$ e acomodar a superdispersão

(quando a variabilidade dos dados é maior do que a média) por meio de um parâmetro de dispersão ϕ:

$$\text{Var}(Y_t) = \phi \cdot \mu_t$$

O modelo linear generalizado clássico assume uma função de ligação logarítmica incluindo uma tendência temporal t:

$$\ln(\mu_t) = \alpha + \beta t$$

Para mitigar a influência de surtos passados no cálculo da linha de base estatística (o que geraria limites de alerta artificialmente elevados), o algoritmo aplica uma função de ponderação baseada nos resíduos de Anscombe (r_t):

$$w_t = \begin{cases} \frac{1}{r_t^2}, & \text{se } r_t > c \\ 1, & \text{se } r_t \leq c \end{cases}$$

Os limites superiores do intervalo de previsão recebem uma transformação de potência de 2/3 para aproximar a assimetria comum de contagens baixas a uma distribuição normal:

$$\text{Limiar de Alerta (Transformado)} = \hat{\mu}_t^{2/3} + z_{1-\alpha} \cdot \sqrt{\text{Var}(\hat{\mu}_t^{2/3})}$$

A pontuação de alerta (*alert score*) é medida pela distância do valor observado y_t em relação ao esperado $\hat{\mu}_t$ dividida pela amplitude do limite predito:

$$\text{Score} = \frac{y_t - \hat{\mu}_t}{\text{Limiar} - \hat{\mu}_t}$$

Um alerta é formalmente disparado caso a pontuação seja estritamente superior a 1.

1.5.1.2 2. Abordagem modificada (Noufaily et al., 2012)

Para sanar instabilidades em bases de dados muito longas, a versão modificada (`method = "modified"`) altera a distribuição estrutural para uma distribuição de probabilidade **Binomial Negativa**, onde a variância possui uma relação quadrática com a média:

$$\text{Var}(Y_t) = \mu_t + \gamma \mu_t^2$$

Em vez de remover ou reduzir o peso de pontos isolados, o modelo estende a linha de base de forma contínua e aplica fatores de múltiplos níveis para capturar componentes de sazonalidade harmônica e flutuações anuais com maior sensibilidade estatística.

1.5.2 Aplicação em Vigilância Sindrômica

Na arquitetura de sistemas de inteligência epidemiológica, este algoritmo atua de forma automatizada processando contagens agregadas retrospectivas. Ele é o padrão-ouro utilizado internacionalmente por agências ministeriais (como o CDC norte-americano) para monitorar canais endêmicos e disparar notificações institucionais a partir de dados assistenciais coletados na rede de saúde.

1.5.3 Quando Utilizar

- **Dados Semanais:** Estruturado nativamente para operar seguindo o calendário de semanas epidemiológicas (MMWR).
- **Séries históricas de longo prazo:** Exige janelas extensas de treinamento, requerendo um mínimo absoluto de 3 anos (com padrão recomendado de **4 a 5 anos** de registros anteriores).
- **Vigilância de doenças transmissíveis:** Excelente desempenho para acompanhar agravos crônicos, endemias estabilizadas ou surtos sazonais previsíveis (ex: dengue, infecções respiratórias).
- **Detecção de surtos agudos:** Capacidade de identificar anomalias localizadas em termos de volume bruto dentro do território de interesse.

1.5.4 Vantagens

- **Respaldo científico:** Metodologia amplamente respaldada, consolidada e validada pela literatura epidemiológica internacional.
- **Correção de superdispersão:** Trata a flutuação excessiva de dados de contagem em serviços de saúde através das estruturas Quase-Poisson ou Binomial Negativa.
- **Bom desempenho para eventos raros:** A transformação matemática de potência garante estabilidade e evita

1.5.5 Implementação no R com `RNSSP`

No pacote `Rnssp` o Detector Temporal de Farrington esta implementado usando a função (`alert_farrington`).

Função: `alert_farrington(df, t = date, y = count, B = 4, g = 27, w = 3, p = 10, method = "original")`

1.5.6 Argumentos e Parâmetros

- `df`, `t`, `y`: Mesma definição padrão descrita no EWMA (Data frame, coluna temporal e de contagens).
- `B` **(Anos de Baseline):** Número de anos históricos incluídos no treinamento. O algoritmo exige um mínimo de 3 anos, tendo **4 anos** como o valor padrão.
- `g` **(Margem de Segurança Semanal):** O número de semanas que separa a semana do teste atual do bloco de referência histórico anterior. O padrão é **27 semanas** de guarda.
- `w` **(Janela Homóloga):** Metade da largura da janela temporal biológica. O modelo vai analisar a mesma data nos anos anteriores, incluindo `w` semanas antes e `w` semanas depois da data de referência. O padrão é **3 semanas** (formando uma janela total de 7 semanas por ano).
- `p`: Quantidade de períodos sazonais identificados por ano na base de treinamento. O padrão é **10**.
- `method`: String de texto definindo a variação matemática da modelagem:
  - `"original"` (padrão): Ajusta um modelo **Quase-Poisson** com pesos adaptativos (resíduos de Anscombe) para limpar surtos do passado.
  - `"modified"`: Implementa a abordagem de Noufaily (2012), que assume uma distribuição **Binomial Negativa**, estende a linha de base e inclui um fator de 10 níveis para corrigir minuciosamente a sazonalidade.

```r
##  Algoritimo Farrington
#### Example 1

df <- data.frame(
  date = seq(as.Date("2014-01-05"), as.Date("2022-02-05"), "weeks"),
  count = rpois(length(seq(as.Date("2014-01-05"), as.Date("2022-02-05"), "weeks")), 25)
)
```

```r
head(df)
```

```
##         date count
## 1 2014-01-05    26
## 2 2014-01-12    29
## 3 2014-01-19    22
## 4 2014-01-26    27
## 5 2014-02-02    25
## 6 2014-02-09    21
```

```r
## Original Farrington algorithm
df_farr_original <- alert_farrington(df, t = date, y = count)
head(df_farr_original)
```

```
## # A tibble: 6 x 8
##   date       count predicted time_coefficient include_time_term upper
##   <date>     <int>     <dbl>            <dbl> <lgl>              <dbl>
## 1 2014-01-05    26        NA               NA NA                    NA
## 2 2014-01-12    29        NA               NA NA                    NA
## 3 2014-01-19    22        NA               NA NA                    NA
## 4 2014-01-26    27        NA               NA NA                    NA
## 5 2014-02-02    25        NA               NA NA                    NA
## 6 2014-02-09    21        NA               NA NA                    NA
## # i 2 more variables: alert_score <dbl>, alert <chr>
```

```r
## Modified Farrington algorithm
df_farr_modified <- alert_farrington(df, t = date, y = count, method = "modified")
head(df_farr_modified)
```

```
## # A tibble: 6 x 8
##   date       count predicted time_coefficient include_time_term upper
##   <date>     <int>     <dbl>            <dbl> <lgl>              <dbl>
## 1 2014-01-05    26        NA               NA NA                    NA
## 2 2014-01-12    29        NA               NA NA                    NA
## 3 2014-01-19    22        NA               NA NA                    NA
## 4 2014-01-26    27        NA               NA NA                    NA
## 5 2014-02-02    25        NA               NA NA                    NA
## 6 2014-02-09    21        NA               NA NA                    NA
## # i 2 more variables: alert_score <dbl>, alert <chr>
```

1.6 Modelo Binomial Negativo

1.6.1 Conceito Estatístico

O modelo de regressão Binomial Negativo surge como uma alternativa estatística rigorosa para dados de contagem sob a presença de **superdispersão extrema**, cenário onde a distribuição de Poisson clássica falha por impor a restrição de equidispersão, isto é:

$$\text{Var}(Y) = E(Y)$$

Epidemiologicamente, a superdispersão manifesta-se em decorrência da heterogeneidade espacial e individual não observada, subnotificações variáveis, aglomeração de casos (*clustering*) e eventos de supertransmissão (*superspreading events*), onde a variância dos dados supera significativamente a média:

$$\mathrm{Var}(Y_t) > E(Y_t)$$

A distribuição Binomial Negativa ($Y_t \sim \mathrm{BN}(\mu_t, \theta)$) pode ser elegantemente compreendida como uma **mistura contínua Poisson-Gama**. Sob essa ótica, a taxa de contagem média de Poisson é tratada não como uma constante fixa, mas como uma variável aleatória que segue uma distribuição Gama com parâmetro de forma/dispersão θ. A estrutura de variância resultante possui comportamento quadrático:

$$\mathrm{Var}(Y_t) = \mu_t + \frac{\mu_t^2}{\theta}$$

Onde θ representa o parâmetro de dispersão (também chamado de parâmetro de tamanho ou *size*). Note que, quando $\theta \to \infty$, o termo quadrático vanish e o modelo converge exatamente para a distribuição de Poisson.

O modelo de regressão linearizado via função de ligação *log* permite incorporar tendências seculares e flutuações sazonais através de termos harmônicos (Serfling expandido):

$$\log(\mu_t) = \beta_0 + \beta_1 t + \sum_{j=1}^{M} \left[\gamma_j \sin\left(\frac{2\pi j t}{s}\right) + \delta_j \cos\left(\frac{2\pi j t}{s}\right) \right]$$

Os limites superiores de detecção (limiares epidêmicos) são derivados diretamente dos quantis exatos da distribuição Binomial Negativa condicional estimada, garantindo taxas de Erro Tipo I estáveis e robustas contra caudas pesadas.

1.6.1.1 Complemento Teórico: Diagnóstico de Superdispersão

Para justificar formalmente a transição do modelo de Poisson para o Binomial Negativo, aplica-se o Teste de Razão de Verossimilhança (*Likelihood Ratio Test - LRT*) comparando os dois modelos ajustados sob as mesmas covariáveis. A estatística de teste é definida por:

$$LR = 2 \times (\ln L_{BN} - \ln L_{Poisson})$$

Sob a hipótese nula de equidispersão ($H_0 : \frac{1}{\theta} = 0$), a estatística LR distribui-se assintoticamente como uma mistura de distribuições Qui-quadrado ($\frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$), permitindo a validação do modelo mais complexo se p-valor $< \alpha$.

1.6.2 Aplicação em Vigilância Sindrômica

- Modelagem de séries temporais altamente instáveis ou com picos estocásticos pronunciados.
- Vigilância epidemiológica de síndromes raras em recortes geográficos pequenos (bairros, distritos sanitários ou regiões de saúde de pequeno porte).
- Séries de dados hospitalares de pronto-socorro caracterizados por alta volatilidade semanal.

1.6.3 Quando utilizar

- Séries de contagem que falham sistematicamente nos testes de diagnóstico de equidispersão de Poisson.
- Monitoramento de dados epidemiológicos desagregados por subpopulações, faixas etárias ou pequenas regiões onde o efeito de pequenos números amplifica a variabilidade estocástica.

1.6.4 Vantagens

- **Ajuste robusto da variância:** Mapeamento preciso e direto do espalhamento dos dados sem a necessidade de depender de aproximações assintóticas normais (como a transformação de Wilson-Hilferty).
- **Redução drástica de falsos alertas:** Ao assumir a variância ampliada real da dinâmica de transmissão, os limites de controle expandem-se de forma estatisticamente justa nos períodos de maior oscilação natural, evitando que flutuações normais disparem falsos alarmes de surto.

1.6.5 Limitações

- A estimação de parâmetros via Máxima Verossimilhança requer algoritmos numéricos iterativos que podem falhar ou não convergir em séries com inflação extrema de zeros (*zero-inflation*). Nestes casos específicos, modelos do tipo *Zero-Inflated Negative Binomial* (ZINB) tornam-se necessários.
- A interpretação matemática e o monitoramento do coeficiente de dispersão (θ) exigem maior perícia estatística por parte do analista.

1.6.6 Implementação no R com `RNSSP`

Dentro do ecossistema de análise de dados do `RNSSP`, os modelos customizados baseados na distribuição de probabilidade Binomial Negativa podem ser integrados utilizando funções preditivas e o pacote estatístico `MASS` para a estimação robusta de θ e vamos usar o comando (`alert_nbinom`).

Função: `alert_nbinom(df, t = date, y = count, include_time = TRUE, baseline_end)`

1.6.7 Argumentos e Parâmetros

- **`df`**, **`t`**, **`y`**: Formato padrão de entrada de dados do pacote.
- **`include_time`**: Valor lógico (`TRUE` ou `FALSE`). Define se o modelo deve incluir uma variável de tendência linear para controlar se a série está subindo ou descendo de forma estrutural ao longo dos anos. O padrão é **`TRUE`**.
- **`baseline_end`**: Argumento **obrigatório** (formato `Date`). Determina exatamente o marco temporal em que a fase de treinamento/baseline acaba e o período de previsão/testagem em tempo real começa.

```r
# Example 1

df <- data.frame(
  date = seq(as.Date("2014-01-05"), as.Date("2022-02-05"), "weeks"),
  count = rpois(length(seq(as.Date("2014-01-05"), as.Date("2022-02-05"), "weeks")), 25)
)

head(df)
```

```
##         date count
## 1 2014-01-05    27
```

```
## 2 2014-01-12    28
## 3 2014-01-19    15
## 4 2014-01-26    35
## 5 2014-02-02    26
## 6 2014-02-09    31
```

```
df_nbinom <- alert_nbinom(df, baseline_end = as.Date("2020-03-01"))

head(df_nbinom)
```

```
## # A tibble: 6 x 7
##   date       count split           estimate threshold alarm time_term
##   <date>     <dbl> <fct>              <dbl>     <dbl> <lgl> <lgl>
## 1 2014-01-05    27 Baseline Period     24.7        35 FALSE TRUE
## 2 2014-01-12    28 Baseline Period     24.7        34 FALSE TRUE
## 3 2014-01-19    15 Baseline Period     24.7        34 FALSE TRUE
## 4 2014-01-26    35 Baseline Period     24.7        34 TRUE  TRUE
## 5 2014-02-02    26 Baseline Period     24.7        34 FALSE TRUE
## 6 2014-02-09    31 Baseline Period     24.7        34 FALSE TRUE
```

```
# Example 2
library(ggplot2)

simulated_ts <- simulated_data

## Time series with seasonality, moderate counts
ts <- subset(simulated_ts, id == "Scenario #1")

head(ts)
```

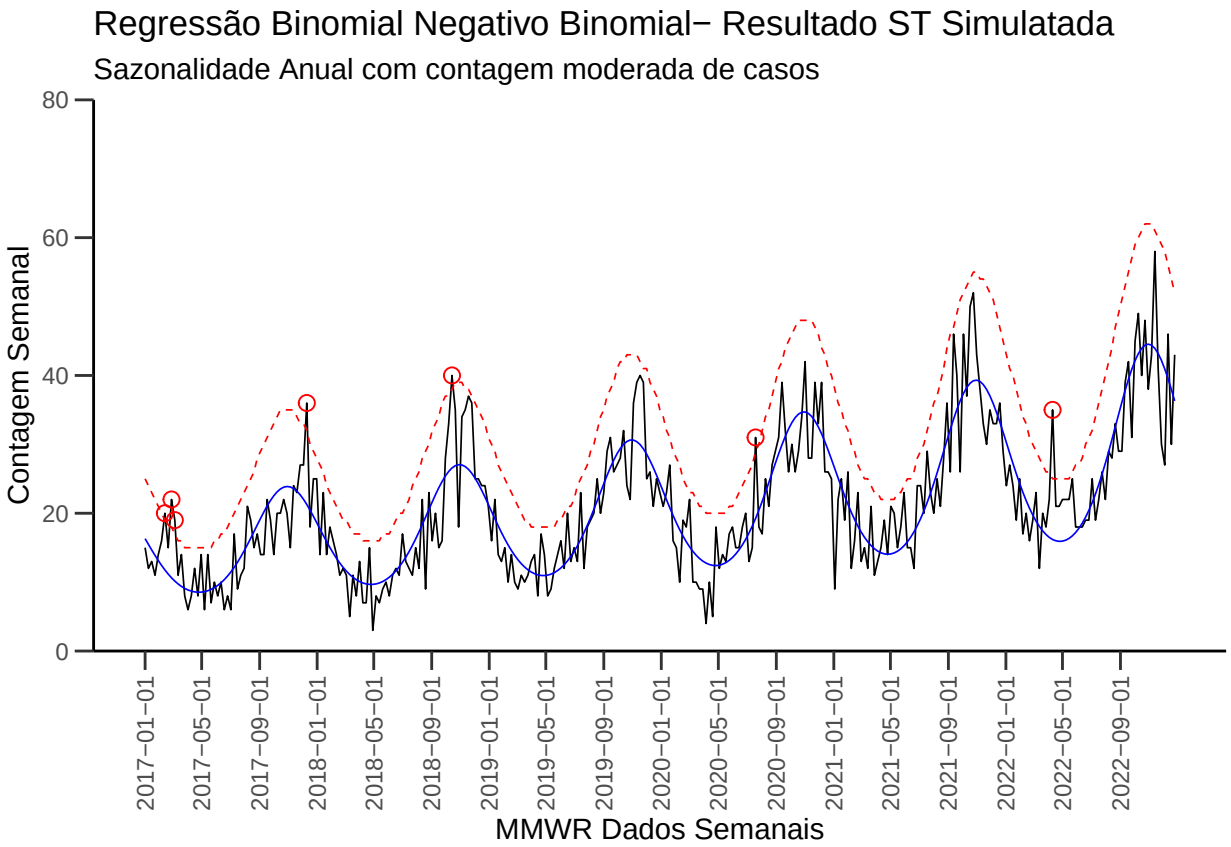
```
## # A tibble: 6 x 5
##   date        week  year cases id
##   <date>     <dbl> <dbl> <dbl> <chr>
## 1 2017-01-01     1  2017    15 Scenario #1
## 2 2017-01-08     2  2017    12 Scenario #1
## 3 2017-01-15     3  2017    13 Scenario #1
## 4 2017-01-22     4  2017    11 Scenario #1
## 5 2017-01-29     5  2017    14 Scenario #1
## 6 2017-02-05     6  2017    16 Scenario #1
```

```
df_nbinom <- alert_nbinom(ts, t = date, y = cases,
                          baseline_end = as.Date("2021-12-26"))

head(df_nbinom)
```

```
## # A tibble: 6 x 10
##   date        week  year cases id       split estimate threshold alarm time_term
##   <date>     <dbl> <dbl> <dbl> <chr>    <fct>    <dbl>     <dbl> <lgl> <lgl>
## 1 2017-01-01     1  2017    15 Scenari~ Base~     16.3        25 FALSE TRUE
## 2 2017-01-08     2  2017    12 Scenari~ Base~     15.5        24 FALSE TRUE
## 3 2017-01-15     3  2017    13 Scenari~ Base~     14.7        23 FALSE TRUE
## 4 2017-01-22     4  2017    11 Scenari~ Base~     13.9        22 FALSE TRUE
## 5 2017-01-29     5  2017    14 Scenari~ Base~     13.1        21 FALSE TRUE
## 6 2017-02-05     6  2017    16 Scenari~ Base~     12.4        20 FALSE TRUE
```

```r
## Visualize alert
df_nbinom %>%
  ggplot() +
  theme_classic() +
  geom_line(aes(x = date, y = cases), linewidth = 0.3) +
  geom_line(aes(x = date, y = estimate), color = "blue", linewidth = 0.3) +
  geom_line(aes(x = date, y = threshold), color = "red", linewidth = 0.3,
            linetype = "dashed") +
  geom_point(data = subset(df_nbinom, alarm), aes(x = date, y = cases),
             color = "red", shape = 21, size = 2.5) +
  scale_y_continuous(
    limits = c(0, 80),
    expand = c(0, 0),
    name = "Contagem Semanal"
  ) +
  scale_x_date(
    breaks = seq.Date(from = min(ts$date), to = max(ts$date), by = "4 months"),
    name = "MMWR Dados Semanais"
  ) +
  theme(
    axis.text.x = element_text(angle = 90, vjust = 0.5),
    axis.ticks.length = unit(0.25, "cm")
  ) +
  labs(
    title = "Regressão Binomial Negativo Binomial- Resultado ST Simulatada",
    subtitle = "Sazonalidade Anual com contagem moderada de casos"
  )
```


Regressão Binomial Negativo Binomial− Resultado ST Simulatada
Sazonalidade Anual com contagem moderada de casos
Contagem Semanal
0
20
40
60
80
2017−01−01
2017−05−01
2017−09−01
2018−01−01
2018−05−01
2018−09−01
2019−01−01
2019−05−01
2019−09−01
2020−01−01
2020−05−01
2020−09−01
2021−01−01
2021−05−01
2021−09−01
2022−01−01
2022−05−01
2022−09−01
MMWR Dados Semanais

1.7

2 Comparação dos métodos

Em suma, a escolha do método ideal no pacote Rnssp exige o equilíbrio entre a frequência de atualização dos dados (diária ou semanal) e a extensão do histórico disponível, permitindo que algoritmos simples capturem anomalias imediatas enquanto modelos complexos isolam padrões sazonais de longo prazo.Deste modo, não existe um algoritmo "universalmente superior" na vigilância sindrômica, mas sim ferramentas estatísticas disponíveis cujos desempenhos dependem diretamente da estrutura da série temporal e do ciclo epidemiológico do agravo monitorado.

A tabela abaixo sumariza as características operacionais e propriedades estatísticas de cada abordagem discutida:

Método	Adequado para Séries Curtas	Modelagem da Sazonalidade	Trata Superdispersão	Foco Principal na Vigilância
EWMA	Excelente	Não	Parcial (via variância adaptativa)	Detecção rápida de mudanças bruscas (*shifts*) diárias.
Regressão Adaptativa	Moderada	Excelente (Harmônica)	Parcial	Rastreamento de tendências locais e alertas institucionais.
Regressão/EWMA	Boa	Excelente	Parcial	Sistemas automáticos de alta sensibilidade com controle residual.
Farrington	Moderada	Boa (via Janelas Homólogas)	Excelente (Quase-Poisson)	Padrão para Doenças de Notificação Compulsória semanais.
Binomial Negativo	Moderada	Excelente (via preditores)	Excelente (Estrutura quadrática)	Modelagem de dados altamente dispersos e pequenas populações.
Serfling	Baixa	Excelente (Harmônica)	Não (Base Gaussiana)	Cálculo histórico e monitoramento de excesso de mortalidade por Influenza.

2.0.1 Nota Técnica

Padrões de histórico por frequência de dados para considerar séries curtas, pois diferentemente do Teorema Central do Limite (TCL), que foca na independência dos dados e sugere a regra tradicional do $n \geq 30$), na Vigilância Sindrômica e Epidemiológica o tamanho mínimo da série é ditado pela **frequência da coleta** e pelo **ciclo do evento de saúde em análise**. Conforme temos:

1) Dados diários (Portas de entrada / UPAs)

- **Série Curta:** Menos de 60 a 90 dias. Embora forneça um volume bruto de pontos considerável, o histórico curto impede o mapeamento de sazonalidades amplas (como variações climáticas sazonais), permitindo apenas o controle de variações semanais simples.

- **Modelo Recomendado: EWMA**. Ele se destaca em séries curtas porque calcula uma média ponderada focada nos dias mais recentes, exigindo uma janela basal mínima pequena (frequentemente de **7 a 28 dias**) para calibração e disparo de alertas rápidos

2) Dados semanais (Semanas Epidemiológicas)

- **Série Curta:** Menos de 2 a 3 anos (104 a 156 semanas). ***Modelo Recomendado:** Algoritmos como **Farrington** ou **Serfling**Para que o algoritmo consiga diferenciar uma flutuação sazonal esperada (como o aumento de síndromes respiratórias no inverno) de um surto real de grande magnitude, são necessários de **3 a 5 anos de histórico anterior** para consolidar uma linha de base estatisticamente robusta.

3) Dados mensais ou anuais (Análise de tendência de longo prazo)

- **Série Curta:** Menos de 36 meses (para dados mensais) ou menos de 10 a 15 anos (para dados anuais).
- **Modelo Recomendado: Modelos de Regressão estruturados** ou **Binomial Negativo** , que demandam múltiplos ciclos sazonais completos para ajustar corretamente seus parâmetros matemáticos e isolar fatores de confusão populacionais.

2.0.2 Critérios práticos e técnicos da escolha do algoritmo

A seleção ótima do algoritmo estatístico para compor um sistema de vigilância sindrômica deve ser pautada nos seguintes critérios de consistência:

- **Granularidade e frequência dos dados:** Dados diários operacionais respondem melhor a abordagens adaptativas locais (EWMA, Regressão Adaptativa). Dados semanais consolidados encontram consistência em Farrington ou Serfling.
- **Padrão de dispersão:** Se a análise exploratória indicar uma variância significativamente superior à média ($\text{Var}(Y) \gg E(Y)$), é mandatório adotar o modelo **Binomial Negativo** ou **Farrington**, sob o risco de gerar uma avalanche de alarmes falsos decorrentes da subestimação dos limites de controle.
- **Disponibilidade de histórico:** O método de **Serfling** e o **Farrington** demandam maturidade de dados históricos (anos de observação retrospectiva). Na ausência destes, algoritmos de suavização exponencial ponderada fornecem respostas imediatas aceitáveis.

Em termos gerais:

- **EWMA** é recomendado para monitoramento operacional diário.
- **Regressão Adaptativa** é indicada para séries com sazonalidade bem definida.
- **Regressão/EWMA** é adequada para cenários que exigem elevada sensibilidade.
- **Farrington** é amplamente utilizado para doenças de notificação compulsória.
- **Binomial Negativo** é recomendado para dados altamente dispersos.
- **Serfling** permanece como referência para vigilância de doenças respiratórias sazonais.

---

3 Referencias Bibliográficas

EWMA

ROBERTS, S. W. Control chart tests based on geometric moving averages. Technometrics, Alexandria, v. 1, n. 3, p. 239–250, 1959. DOI: 10.1080/00401706.1959.10489860.

Método de Serfling

SERFLING, R. E. Methods for current statistical analysis of excess pneumonia-influenza deaths. Public Health Reports, Washington, v. 78, n. 6, p. 494–506, 1963. DOI: 10.2307/4591848.

Detector de Farrington

FARRINGTON, C. P.; ANDREWS, N. J.; BEALE, A. D.; CATCHPOLE, M. A. A statistical algorithm for the early detection of outbreaks of infectious disease. Journal of the Royal Statistical Society: Series A (Statistics in Society), London, v. 159, n. 3, p. 547–563, 1996. DOI: 10.2307/2983331.

Farrington

NOUFAILY, A.; ENKI, D. G.; FARRINGTON, P.; GARTHWAITE, P.; ANDREWS, N.; CHARLETT, A. An improved algorithm for outbreak detection in multiple surveillance systems. Statistics in Medicine, Hoboken, v. 32, n. 7, p. 1206–1222, 2013.

Vigilância Estatística em Saúde Pública

BROOKMEYER, R.; STROUP, D. F. Monitoring the health of populations: statistical principles and methods for public health surveillance. New York: Oxford University Press, 2004.

Referência clássica sobre Detecção em Vigilância

STROUP, D. F.; WILLIAMSON, G. D.; HERNDON, J. L. Detection of aberrations in the occurrence of notifiable diseases surveillance data. Statistics in Medicine, Chichester, v. 8, n. 3, p. 323–329, 1989.

Referência Computacional do Pacote surveillance

SALMON, M.; SCHUMACHER, D.; HÖHLE, M. Monitoring count time series in R: aberration detection in public health surveillance. Journal of Statistical Software, Los Angeles, v. 70, n. 10, p. 1–35, 2016.

Referência Geral sobre Vigilância Sindrômica

HENNING, K. J. What is syndromic surveillance? Morbidity and Mortality Weekly Report, Atlanta, v. 53, Suppl., p. 5–11, 2004.

AZONDEKON, Gbedegnon Roseric; SHEPPARD, Michael. Rnssp: a signature R package for the National Syndromic Surveillance Program (NSSP). Versão 0.3.1. Atlanta: Centers for Disease Control and Prevention, 2025. Software. Disponível em: https://github.com/CDCgov/Rnssp. Acesso em: 29 jun. 2026. DOI: https://doi.org/10.5281/zenodo.16929440.